

Trabajo Práctico 2

Laboratorio de Datos - Instituto de Cálculo
Facultad de Ciencias Exactas y Naturales - Universidad de Buenos Aires

Grupo N° 3:
Gesualdi Santiago y Palmer Candela Magalí

2026-06-30

Índice

1. Introducción	2
2. Metodología	3
3. Resultados	6
4. Discusiones	14
5. Referencias	15
6. Anexos	16
6.1. Anexo I: Datos faltantes	16
6.2. Anexo II: Variación intra e inter clusters	17

1 Introducción

El mercado inmobiliario es un sector dinámico cuya comprensión resulta fundamental para diversos actores económicos y sociales. En este contexto, el presente informe analiza un conjunto de datos que reúne información sobre precios de viviendas en la Ciudad Autónoma de Buenos Aires (CABA) y el Gran Buenos Aires correspondiente al año 2020. Los datos analizados provienen de la plataforma Kaggle, en particular a “Buenos Aires Real State on sale” (*Properati Data, 2020*) y han sido adaptados con fines didácticos para este estudio. La importancia de abordar este análisis radica en la necesidad de identificar qué factores, ya sean características edilicias (como superficie, cantidad de ambientes o baños) o localización geográfica, inciden de manera determinante en la valoración de una propiedad. Comprender estas relaciones es clave para interpretar el funcionamiento del mercado, detectar patrones de comportamiento y aportar evidencia que permita tomar decisiones informadas en contextos de compra, venta o planificación urbana. Además, el mercado inmobiliario presenta una marcada heterogeneidad, propiedades con configuraciones similares pueden exhibir precios muy distintos según su ubicación, distribución interna o condiciones edilicias. Esta variabilidad hace que el análisis estadístico y el modelado predictiva resulten herramientas especialmente valiosas para estudiar esta dinámica. En este trabajo se emplean métodos de regresión lineal simple y múltiple para evaluar la capacidad de distintas variables de explicar el precio de las viviendas, así como técnicas de agrupamiento para identificar conjuntos de propiedades con características estructurales comparables dentro de la región de Capital Federal. El problema central que busca resolver este trabajo es la identificación de patrones y relaciones entre las variables físicas de las viviendas y su valor de mercado, así como la agrupación de las propiedades en conjuntos con características homogéneas. En función de ello, el objetivo principal del informe es evaluar la capacidad predictiva de distintos modelos y caracterizar los grupos resultantes, aportando una visión integral del comportamiento del mercado inmobiliario en el área analizada.

2 Metodología

El presente estudio utilizó como insumo principal una base de datos relativa al mercado inmobiliario de la Ciudad Autónoma de Buenos Aires y el Gran Buenos Aires, proveniente de la plataforma Kaggle(Properati Data, 2020). El flujo de trabajo se estructuró en tres etapas principales, preprocesamiento del dataset, modelado predictivo mediante regresión lineal y agrupamiento no supervisado (este último aplicado únicamente a viviendas de Capital Federal) y comunicación, siguiendo el ciclo de vida de un proyecto de ciencia de datos robusto (*Nina Zumel and John Mount, 2020*). Todas las tareas se realizaron en R (*R Core Team, 2024*), desde la depuración de los datos hasta el modelado y la comunicación de resultados.

En las *Tabla 1* y *Tabla 2* se puede ver una descripción estadística de las variables del dataset original.


Tabla 1: Estadísticos descriptivos de las variables numéricas

Variable	Media	Mediana	Desvío estándar	Mínimo	Máximo	Datos Faltantes
Baños	1.54	1.0	0.80	1	14	1,232
Dormitorios	2.03	2.0	1.05	0	15	0
Precio	212,518.37	167,949.5	150,116.63	15,859	999,999	0
Ambientes	3.07	3.0	1.30	1	16	0
Superficie cubierta	87.09	66.0	73.94	11	5,250	0
Superficie total	132.27	76.0	197.78	11	5,650	0

Tabla 2: Distribución de frecuencias de las variables categóricas principales

Categoría	Frecuencia absoluta	Frecuencia relativa	Datos faltantes
Región			
Capital Federal	59,124	0.66	0
Zona Norte	15,937	0.18	0
Zona Sur	8,070	0.09	0
Zona Oeste	6,297	0.07	0
Tipo de propiedad			
Departamento	67,503	0.75	0
Casa	11,486	0.13	0
PH	10,439	0.12	0

En la fase inicial de preprocesamiento, se realizó una limpieza orientada al tratamiento de valores faltantes, observaciones atípicas, corrección de inconsistencias estructurales y el recorte de valores extremos, aplicando técnicas de limpieza y transformación bajo el marco de *tidy data* para asegurar la consistencia del análisis (Hadley Wickham and Mine Çetinkaya-Rundel and Garrett Grolemund, 2023). En particular, los valores faltantes de “Baños” se imputaron mediante la mediana condicionada por tipo de propiedad y cantidad de ambientes, aprovechando la fuerte relación entre estas variables. Asimismo, se eliminaron observaciones con superficies cubiertas mayores a las totales o con cantidades de dormitorios superiores al número de ambientes. Para reducir la influencia de valores atípicos, se recortaron las colas superiores del 1 % en las variables de superficie (vease *Figura 1*) y se filtraron precios mayores a 999,999 USD. Sobre la base depurada se construyó la variable “Precio por m²”, utilizada en los análisis posteriores.



(a) Conjunto completo, con colas largas.

(b) Tras recortar el percentil 99 superior.

Figura 1: Distribución de la superficie cubierta de las propiedades (escala logarítmica).

Para la identificación de los factores con mayor influencia en el valor de las propiedades, se realizó un Análisis Exploratorio de Datos (EDA), el cual incluyó la elaboración de tablas descriptivas y gráficos de distribución, así como el análisis de correlación entre las variables estructurales de las propiedades. La matriz de correlación (Figura 2) permitió identificar a “Baños”, “Superficie cubierta”, “Ambientes” y “Dormitorios” como las variables con mayor asociación lineal con el precio. Estas predictoras fueron evaluadas individualmente mediante modelos de regresión lineal simple, cuya capacidad de generalización se estimó mediante validación cruzada de 10 folds implementada con caret. Para cada modelo se registraron métricas de desempeño como el r^2 y el MSE. Aunque la variable “Baños” presentó el menor error promedio, su naturaleza discreta generó un ajuste deficiente, por lo que se seleccionó “Superficie cubierta” como predictora final para la regresión lineal simple.




Figura 2: Matrices de correlación.

Para el desarrollo del modelo de Regresión Lineal Múltiple, se utilizó la función `lm()` para predecir el precio de las viviendas. La identificación del conjunto óptimo de variables predictoras se realizó mediante un algoritmo de selección forward, el cual incorpora variables de manera secuencial basándose en la mejora del ajuste estadístico (Gareth James and Daniela Witten and Trevor Hastie and Robert Tibshirani, 2021). Con el fin de mitigar el riesgo de sobreajuste y asegurar la capacidad de generalización del modelo, la selección no se limitó al error de entrenamiento, sino que se empleó una estrategia de Validación Cruzada (Cross-Validation) de 10 folds. Bajo este esquema, se seleccionó el modelo que minimizó el Error Cuadrático Medio (MSE) promedio de validación.

En una segunda instancia, se abordó la segmentación de las viviendas en Capital Federal mediante un análisis de agrupamiento no supervisado utilizando el algoritmo K-means. Dado que este método es sensible a

las escalas de medición, se procedió a la estandarización de las variables numéricas (superficie y ambientes) para garantizar que todas tuvieran el mismo peso relativo en el cálculo de las distancias euclidianas (*Alboukadel Kassambara, 2017*). El número óptimo de clústeres se determinó mediante el Método del Codo (Elbow Method), identificando el punto de inflexión donde la Suma de Cuadrados Intra-clúster (WSS) comienza a estabilizarse. Finalmente, la calidad y cohesión de los segmentos obtenidos se validó a través del coeficiente de Silhouette (Silueta), evaluando la relación entre la disimilitud interna de los grupos y su separación externa (*Peter J. Rousseeuw, 1987*).

3 Resultados




Figura 3: Distribución del precio de venta de las propiedades.




Figura 4: Distribución del precio mediano por m^2 según región.




Figura 5: Precio mediano por m^2 por barrio o localidad del Gran Buenos Aires, segmentado por zona. Las barras representan el rango intercuartílico.




Figura 6: Precio mediano por m^2 por barrio o localidad del Gran Buenos Aires, segmentado por zona. Las barras representan el rango intercuartílico.





Figura 7: Precio de venta según (a) tipo de propiedad y (b) región.


Tabla 3: Modelos de RLS ordenados por capacidad explicativa.

Predictora	r^2	MSE ($\times 10^9$)	RMSE ($\times 10^4$) [USD]
Baños	0.40	12.75	11.29
Superficie cubierta	0.39	12.93	11.37
Ambientes	0.25	15.93	12.62
Dormitorios	0.24	16.04	12.66

Si bien la variable bathrooms es la que menos RMSE presenta, al ser discreta y no continua, no construye un buen modelo predictivo para price por si sola, esto incluso lo podemos visualizar en el siguiente scatter plot donde se observa que claramente no hay una relacion linear y el modelo no ajusta bien. Por lo que, elegiremos surface_covered como variable predictora



(a) Recta ajustada sobre los datos.



(b) Residuos frente a la superficie cubierta.

Figura 8: Regresión lineal simple del precio sobre la superficie cubierta (muestra aleatoria de 15.000 propiedades).

Tabla 4: Comparación de modelos de RLM según variables predictoras utilizadas respectivamente.

Modelo	Predictoras (acumuladas)	MSE validación ($\times 10^9$)	MSE entrenamiento ($\times 10^9$)
M 1	Baños	12.75	12.75
M 2	+ Barrio/Localidad	9.52	9.50
M 3	+ Superficie cubierta	6.66	6.65
M 4	+ Tipo de propiedad	6.12	6.10
M 5	+ Superficie total	6.11	6.10
M 6	+ Ambientes	6.10	6.09
M 7	+ Dormitorios	6.10	6.08
M 8	+ Región	6.10	6.08

Para determinar la cantidad óptima de variables en el modelo de regresión lineal múltiple, analizamos el MSE de validación obtenido mediante validación cruzada para modelos con 1 a 8 predictoras. La curva de MSE muestra una disminución pronunciada entre 1 y 3 variables, seguida de una mejora moderada al incorporar la cuarta. A partir de ese punto, el MSE se estabiliza y las diferencias entre modelos más complejos son marginales (del orden de 0.02×10^9), lo cual resulta irrelevante dada la escala de la variable respuesta. Por criterios de parsimonia y estabilidad, seleccionamos el modelo con 4 variables, correspondiente al punto de inflexión (“codo”) de la curva. Este modelo logra un equilibrio adecuado entre capacidad predictiva y complejidad, evitando incorporar predictoras que no aportan mejoras significativas en la generalización.




Figura 9: Error cuadrático medio de validación cruzada según el número de variables incluidas en el modelo de RLM.




Figura 10: Precios predichos por el modelo final de RLM frente a los precios reales observados.

Para evitar problemas de memoria y acelerar el cálculo, se utilizó una muestra aleatoria de 5,000 observaciones, suficiente para capturar la estructura general del dataset y obtener una estimación estable del número óptimo de clústeres.

Tabla 5: Barrios de CABA más valorizados por precio por m² cubierto (mín. 200 registros).

Barrio	Cantidad	Mediana del precio [USD]	Mediana del precio por m ² [USD/m ²]
Puerto Madero	828	545,000	5,779
Las Cañitas	465	340,000	4,000
Nuñez	1,291	210,000	3,553
Palermo	8,670	220,000	3,544
Belgrano	4,292	250,000	3,515
Recoleta	3,898	285,045	3,383
Villa Urquiza	2,183	175,000	3,182
Barrio Norte	2,273	230,000	3,158

Columna 'surface_covered' -> Cantidad de atípicos superiores: 3344

##

```
## Columna 'rooms' -> Cantidad de atípicos superiores: 253
```

```
##
```

```
## -----
```

```
## Columna 'bedrooms' -> Cantidad de atípicos superiores: 292
```

```
##
```

```
## -----
```

```
## Columna 'bathrooms' -> Cantidad de atípicos superiores: 1274
```

```
##
```

```
## -----
```




Figura 11: Método del codo: suma de cuadrados intra-clúster (WSS) en función del número de clústeres k.

El codo se observa en $k = 4$, donde la disminución de WSS deja de ser pronunciada. Por encima de ese valor, las mejoras marginales son pequeñas, indicando que 4 clústeres capturan adecuadamente la estructura del conjunto de datos.




Figura 12: Segmentos de viviendas de CABA proyectados sobre las dos primeras componentes principales (muestra de 5.000 propiedades).

Tabla 6: Estadísticas de los 4 segmentos categorizados de viviendas en CABA.

Categoría	Cantidad	Sup. cubierta (m ²)	Ambientes	Dormitorios	Baños	Precio [USD]
1 · Básica	23,276	42.58	2	1	1	135,668
2 · Estándar	20,989	70.61	3	2	1	205,091
3 · Alta	11,534	115.39	4	3	2	357,149
4 · Elevada	3,062	209.22	5	4	3	512,372




Figura 13: Gráfico de siluetas del agrupamiento k -means ($k = 4$) sobre una submuestra de 1.500 propiedades de CABA. Cada barra es el ancho de silueta S_i de una propiedad, ordenadas dentro de cada segmento: valores cercanos a 1 indican una asignación nítida a su grupo, próximos a 0 una propiedad en la frontera entre segmentos, y negativos una posible mala asignación. La línea punteada marca el ancho de silueta promedio, medida global de la calidad del agrupamiento.

El ancho de silueta promedio es moderado y positivo, lo que confirma que los cuatro segmentos están razonablemente cohesionados y separados. Los segmentos compactos y premium —los extremos de superficie— exhiben siluetas más altas, mientras que las pocas barras negativas corresponden a propiedades en la frontera entre los grupos intermedios.


4 Discusiones

5 Referencias

- Alboukadel Kassambara. (2017). *Practical Guide to Cluster Analysis in R: Unsupervised Machine Learning* (Vol. 1). STHDA.
- Gareth James and Daniela Witten and Trevor Hastie and Robert Tibshirani. (2021). *An Introduction to Statistical Learning with Applications in R* (2nd). Springer.
- Hadley Wickham and Mine Çetinkaya-Rundel and Garrett Golemud. (2023). *R for Data Science* (2nd). O'Reilly Media.
- Nina Zumel and John Mount. (2020). *Practical Data Science with R* (2nd). Manning Publications Co.
- Peter J. Rousseeuw. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Properati Data. (2020). *Buenos Aires Real State on sale*. Kaggle. Consultado el 15 de junio de 2026, desde <https://www.kaggle.com/datasets/alejandromendivil/bsas-realstate-on-sale>
- R Core Team. (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>

6 Anexos

6.1 Anexo I: Datos faltantes



6.2 Anexo II: Variación intra e inter clusters




Figura 14: Matriz de distancias en el espacio estandarizado (superficie cubierta, ambientes, dormitorios y baños). La diagonal (recuadrada) mide la cohesión intra-clúster como distancia media de las propiedades a su centroide; fuera de la diagonal, la separación inter-clúster entre centroides. Valores bajos en la diagonal y altos fuera de ella indican grupos compactos y bien separados.