

Trabajo Práctico 2

Laboratorio de Datos - Instituto de Cálculo
Facultad de Ciencias Exactas y Naturales - Universidad de Buenos Aires

Grupo N° 3:
Gesualdi Santiago y Palmer Candela Magalí

2026-06-30

Índice

1. Introducción	2
2. Metodología	3
2.1. Descripción de la base de datos	3
2.2. Tratamiento de datos faltantes y atípicos	4
2.3. Modelado de datos	5
3. Resultados	6
4. Discusión	13
4.1. Ventajas del enfoque aplicado	14
4.2. Limitaciones del análisis	14
5. Referencias	15
6. Anexos	16
6.1. Anexo I: Datos faltantes	16
6.2. Anexo II: Matriz de correlación	17
6.3. Anexo III: Distribución del precio por m ² en AMBA.	17
6.4. Anexo IV: Variación intra e inter clústers	19

1 Introducción

El mercado inmobiliario es un sector dinámico cuya comprensión resulta fundamental para diversos actores económicos y sociales. En este contexto, el presente informe analiza un conjunto de datos que reúne información sobre precios de viviendas en la Ciudad Autónoma de Buenos Aires (CABA) y el Gran Buenos Aires correspondiente al año 2020.

La importancia de abordar este análisis radica en la necesidad de identificar qué factores, ya sean características edilicias (como superficie, cantidad de ambientes o baños) o localización geográfica, inciden de manera determinante en la valoración de una propiedad. Comprender estas relaciones es clave para interpretar el funcionamiento del mercado, detectar patrones de comportamiento y aportar evidencia que permita tomar decisiones informadas en contextos de compra, venta o planificación urbana. Además, el mercado inmobiliario presenta una marcada heterogeneidad, propiedades con configuraciones similares pueden exhibir precios muy distintos según su ubicación, distribución interna o condiciones edilicias. Esta variabilidad hace que el análisis estadístico y el modelado predictiva resulten herramientas especialmente valiosas para estudiar esta dinámica. En este trabajo se emplean métodos de regresión lineal simple y múltiple para evaluar la capacidad de distintas variables de explicar el precio de las viviendas, así como técnicas de agrupamiento para identificar conjuntos de propiedades con características estructurales comparables dentro de la región de Capital Federal. El problema central que busca resolver este trabajo es la identificación de patrones y relaciones entre las variables físicas de las viviendas y su valor de mercado, así como la agrupación de las propiedades en conjuntos con características homogéneas. En función de ello, el objetivo principal del informe es evaluar la capacidad predictiva de distintos modelos y caracterizar los grupos resultantes, aportando una visión integral del comportamiento del mercado inmobiliario en el área analizada.

2 Metodología

El presente trabajo hace uso de la base de datos de inmuebles a lo largo del AMBA, brindada por la plataforma Kaggle en “Buenos Aires Real State on sale” (*Properati Data, 2020*), adaptados didácticamente por el personal docente a cargo del curso. El flujo de trabajo se estructuró en cuatro etapas principales, preprocesamiento del dataset y limpieza del mismo, análisis exploratorio por sobre ellos (*EDA*), modelado predictivo mediante regresión lineal y agrupamiento no supervisado (*clustering*) aplicado únicamente a viviendas de Capital Federal. Concluyendo con un trabajo comunicativo sobre los resultados hallados, siguiendo el ciclo de vida de un proyecto de ciencia de datos robusto (*Nina Zumel and John Mount, 2020*). Todas las tareas se realizaron en R (*R Core Team, 2024*), desde la depuración de los datos hasta el modelado y la comunicación de resultados.

2.1 Descripción de la base de datos

La base de datos incluye variables numéricas y categóricas. Las variables numéricas se presentan en *Tabla 1* y comprenden tanto medidas continuas (precio, superficie total y superficie cubierta) como variables discretas asociadas a conteos estructurales, como ambientes, dormitorios y baños. Sus estadísticos descriptivos permiten evaluar la variabilidad del conjunto y la presencia de valores extremos.

Las variables categóricas (país, región, barrio/localidad y tipo de propiedad) se resumen en *Tabla 2* mediante frecuencias absolutas y relativas, lo que facilita identificar la composición del conjunto de datos y la predominancia de ciertas zonas y tipologías, como Capital Federal y el tipo “Departamento”.

Esta caracterización inicial proporciona una visión estructural del conjunto de datos y orienta las decisiones metodológicas posteriores.

Tabla 1: Estadísticos descriptivos de las variables numéricas

Variable	Media	Mediana	Desvío estándar	Mínimo	Máximo	Datos Faltantes
Baños	1.54	1.0	0.80	1	14	1,232
Dormitorios	2.03	2.0	1.05	0	15	0
Precio	212,518.37	167,949.5	150,116.63	15,859	999,999	0
Ambientes	3.07	3.0	1.30	1	16	0
Superficie cubierta	87.09	66.0	73.94	11	5,250	0
Superficie total	132.27	76.0	197.78	11	5,650	0

Tabla 2: Distribución de frecuencias de las variables categóricas principales


Categoría	Frecuencia absoluta	Frecuencia relativa	Datos faltantes
Región			
Capital Federal	59,124	0.66	0
Zona Norte	15,937	0.18	0
Zona Sur	8,070	0.09	0
Zona Oeste	6,297	0.07	0
Tipo de propiedad			
Departamento	67,503	0.75	0
Casa	11,486	0.13	0
PH	10,439	0.12	0

2.2 Tratamiento de datos faltantes y atípicos

En la fase inicial de preprocesamiento, se realizó una limpieza orientada al tratamiento de valores faltantes, observaciones atípicas, corrección de inconsistencias estructurales y el recorte de valores extremos, aplicando técnicas de limpieza y transformación bajo el marco de *tidy data* para asegurar la consistencia del análisis (Hadley Wickham and Mine Çetinkaya-Rundel and Garrett Grolemund, 2023). Los valores faltantes se encontraban exclusivamente en la variable **baños** y fueron imputados considerando la poca cantidad de los mismos frente a la muestra total de 89.428 (véase *Figura ??*). En particular, se poseían 1.232 valores faltantes que fueron imputados utilizando la mediana para evitar posibles perturbaciones por valores fuera del

rango intercuartil, como es comentado próximamente, y por ser una variable discreta (esperamos tener valores siempre enteros para esta variable). Dicha métrica fue calculada sobre una combinación de las variables **tipo de propiedad** y **ambientes** pues se encontró fuerte relación con ellas, puede observarse en *Figura 11*.

Asimismo, se eliminaron observaciones con superficies cubiertas mayores a las totales, pues resulta absurdo dicho caso, y con cantidades de dormitorios superiores al número de ambientes comprendiendo que los primeros se encuentran contenidos por la cantidad de ambientes (ambas son una cuestión de asegurar el análisis pues solo se eliminaron, por ello, 109). Para reducir la influencia de valores atípicos, se suprimió la cola superior al cuantil 0.99 en las variables de **superficie** y **superficie cubierta** (véase *Figura 1*) para garantizar mayor simetría en la distribución y se filtraron precios iguales a 999,999 USD pues, al ser el tope de las mediciones, no es posible distinguir si es un valor real de dichos inmuebles o un tope artificial de la base de datos o de la modificación pedagógica sobre la misma. En función a estos cambios se obtuvo un nuevo conjunto de datos de 87.842‘



(a) Conjunto completo, con colas largas.

(b) Tras recortar el percentil 99 superior.

Figura 1: Distribución de la superficie cubierta de las propiedades (escala logarítmica).

2.3 Modelado de datos

Para la identificación de los factores con mayor influencia en el valor de las propiedades se recurrió al análisis exploratorio de datos, el cual incluyó la elaboración de tablas descriptivas y gráficos de distribución, así como el análisis de correlación entre las variables estructurales de las propiedades. La matriz de correlación *Figura 11* (ya referenciada durante el proceso de imputación) permitió identificar a *baños*, “Superficie cubierta”, “Ambientes” y “Dormitorios” como las variables con mayor asociación lineal con el precio. Estas predictoras fueron evaluadas individualmente mediante modelos de regresión lineal simple, cuya capacidad de generalización se estimó mediante validación cruzada por *k-fold* (*k-fold cross-validation*) con $k = 10$ particiones, implementada con *caret* (Kuhn, Max, 2024), registrando para cada modelo métricas de desempeño

como lo son R^2 y error cuadrático medio (MSE).

Se construyó, a su vez, una regresión lineal múltiple, a través de la función $lm()$, para predecir el precio de las viviendas. La identificación del conjunto óptimo de variables predictoras se realizó mediante un algoritmo de selección directa (*forward*), el cual incorpora variables de manera secuencial basándose en la mejora del ajuste estadístico (Gareth James and Daniela Witten and Trevor Hastie and Robert Tibshirani, 2021). Con el fin de mitigar el riesgo de sobreajuste y asegurar la capacidad de generalización del modelo, la selección no se limitó al error de entrenamiento, sino que se empleó nuevamente validación cruzada con $k = 10$ folds. Bajo este esquema, se seleccionó el modelo que minimizó el MSE promedio de validación.

En una tercera instancia, se abordó la segmentación de las viviendas en Capital Federal mediante un análisis de agrupamiento no supervisado utilizando el algoritmo *K-means*. Dado que este método es sensible a las escalas de medición, se procedió a la estandarización de las variables numéricas para garantizar que todas tuvieran el mismo peso relativo en el cálculo de las distancias euclidianas (Alboukadel Kassambara, 2017). El número óptimo de *clusters* o categorías se determinó mediante el método del codo o *Elbow Method* del inglés, se recomienda lectura (Hansen, 2001), identificando el punto de inflexión donde la Suma de Cuadrados intra-cluster (WSS) comienza a estabilizarse y no resulta altamente superior una categorización mayor. En la práctica se recurrió a estimar para varios valores quedando con el más adecuado (esto se comenta al final del presente trabajo). Finalmente, la calidad y cohesión de los segmentos obtenidos se validó a través del coeficiente de silueta (*silhouette*), evaluando la relación entre la disimilitud interna de los grupos y su separación externa (Peter J. Rousseeuw, 1987).

3 Resultados




Figura 2: Distribución del precio de venta de las propiedades.




Figura 3: Distribución de la mediana de precio por m² según región.




Figura 4: Precio de venta según (a) tipo de propiedad y (b) región.

Tabla 3: Modelos de RLS ordenados por capacidad explicativa.

Predictora	r^2	MSE ($\times 10^9$)	RMSE ($\times 10^4$) [USD]
Baños	0.40	12.75	11.29
Superficie cubierta	0.39	12.93	11.37
Ambientes	0.25	15.93	12.62
Dormitorios	0.24	16.04	12.66

Si bien la variable bathrooms es la que menos RMSE presenta, al ser discreta y no continua, no construye un buen modelo predictivo para price por si sola, esto incluso lo podemos visualizar en el siguiente scatter plot

donde se observa que claramente no hay una relacion linear y el modelo no ajusta bien. Por lo que, elegiremos `surface_covered` como variable predictora




Figura 5: Regresión lineal simple del precio sobre la superficie cubierta (muestra aleatoria de 15.000 propiedades).

Tabla 4: Comparación de modelos de RLM según variables predictoras utilizadas respectivamente.

Modelo	Predictoras (acumuladas)	MSE validación ($\times 10^9$)	MSE entrenamiento ($\times 10^9$)
M 1	Baños	12.75	12.75
M 2	+ Barrio/Localidad	9.52	9.50
M 3	+ Superficie cubierta	6.66	6.65
M 4	+ Tipo de propiedad	6.12	6.10
M 5	+ Superficie total	6.11	6.10
M 6	+ Ambientes	6.10	6.09
M 7	+ Dormitorios	6.10	6.08
M 8	+ Región	6.10	6.08

Para determinar la cantidad óptima de variables en el modelo de regresión lineal múltiple, analizamos el MSE de validación obtenido mediante validación cruzada para modelos con 1 a 8 predictoras. La curva de MSE muestra una disminución pronunciada entre 1 y 3 variables, seguida de una mejora moderada al incorporar la cuarta. A partir de ese punto, el MSE se estabiliza y las diferencias entre modelos más complejos son marginales (del orden de 0.02×10^9), lo cual resulta irrelevante dada la escala de la variable respuesta. Por criterios de parsimonia y estabilidad, seleccionamos el modelo con 4 variables, correspondiente al punto de inflexión (“codo”) de la curva. Este modelo logra un equilibrio adecuado entre capacidad predictiva y complejidad, evitando incorporar predictoras que no aportan mejoras significativas en la generalización.




Figura 6: Error cuadrático medio de validación cruzada según el número de variables incluidas en el modelo de RLM.




Figura 7: Precios predichos por el modelo final de RLM frente a los precios reales observados.

Para evitar problemas de memoria y acelerar el cálculo, se utilizó una muestra aleatoria de 5,000 observaciones, suficiente para capturar la estructura general del dataset y obtener una estimación estable del número óptimo de clústeres.

Tabla 5: Barrios de CABA más valorizados por precio por m² cubierto (mín. 200 registros).

Barrio	Cantidad	Mediana del precio [USD]	Mediana del precio por m ² [USD/m ²]
Puerto Madero	828	545,000	5,779
Las Cañitas	465	340,000	4,000
Nuñez	1,291	210,000	3,553
Palermo	8,670	220,000	3,544
Belgrano	4,292	250,000	3,515
Recoleta	3,898	285,045	3,383
Villa Urquiza	2,183	175,000	3,182
Barrio Norte	2,273	230,000	3,158

Columna 'surface_covered' -> Cantidad de atípicos superiores: 3344

##

Columna 'rooms' -> Cantidad de atípicos superiores: 253

##

Columna 'bedrooms' -> Cantidad de atípicos superiores: 292

##

Columna 'bathrooms' -> Cantidad de atípicos superiores: 1274

##




Figura 8: Método del codo: suma de cuadrados intra-clúster (WSS) en función del número de clústeres k.

El codo se observa en $k = 4$, donde la disminución de WSS deja de ser pronunciada. Por encima de ese valor, las mejoras marginales son pequeñas, indicando que 4 clústeres capturan adecuadamente la estructura del conjunto de datos.




Figura 9: Segmentos de viviendas de CABA proyectados sobre las dos primeras componentes principales (muestra de 5.000 propiedades).

Tabla 6: Estadísticas de los 4 segmentos categorizados de viviendas en CABA.

Categoría	Cantidad	Sup. cubierta (m ²)	Ambientes	Dormitorios	Baños	Precio [USD]
1 · Básica	23,276	42.58	2	1	1	135,668
2 · Estándar	20,989	70.61	3	2	1	205,091
3 · Alta	11,534	115.39	4	3	2	357,149
4 · Elevada	3,062	209.22	5	4	3	512,372




Figura 10: Gráfico de siluetas del agrupamiento k -means ($k = 4$) sobre una submuestra de 1.500 propiedades de CABA. Cada barra es el ancho de silueta S_i de una propiedad, ordenadas dentro de cada segmento: valores cercanos a 1 indican una asignación nítida a su grupo, próximos a 0 una propiedad en la frontera entre segmentos, y negativos una posible mala asignación. La línea punteada marca el ancho de silueta promedio, medida global de la calidad del agrupamiento.

El ancho de silueta promedio es moderado y positivo, lo que confirma que los cuatro segmentos están razonablemente cohesionados y separados. Los segmentos compactos y premium —los extremos de superficie— exhiben siluetas más altas, mientras que las pocas barras negativas corresponden a propiedades en la frontera entre los grupos intermedios.

4 Discusión

Los resultados obtenidos permiten modelar y segmentar el mercado inmobiliario del AMBA con un equilibrio bastante adecuado entre precisión, interpretabilidad y simplicidad. El modelo de regresión lineal múltiple, seleccionado mediante un procedimiento de *forward selection*, demostró ser superior a los modelos de regresión simple ya que capturó de manera conjunta la influencia de la superficie y la cantidad de ambientes en el precio. La incorporación de validación cruzada de 10 folds fue un componente metodológico central pues permitió obtener una estimación insesgada del error de predicción y garantizó que el modelo final posea una buena capacidad de generalización ante datos no observados, evitando el sobreajuste que podría surgir al seleccionar modelos únicamente estimando sobre el subconjunto de entrenamiento.

La naturaleza restrictiva del modelo lineal también resultó ventajosa, ya que facilita la inferencia y permite interpretar directamente el peso relativo de cada predictor. Sobre ello, la mejor variable predictora encontrada fue la cantidad de baños, sin embargo, pertenece a un dominio discreto, hecho por el cual no resulta en la mejor elección para comprar multitud de propiedades que, en general, pueden poseer la misma cantidad de estos. Es así, que se prefirió, como se mostró anteriormente, la utilización de **superficie cubierta** como predictora donde, la diferencia entre los valores de R^2 resulta marginal.

En relación a la variable de superficie total de las propiedades se intuye colinealidad con la superficie cubierta (por estar contenida esta última dentro de la total). Razón por la cual para el análisis de agrupamiento fue seleccionada únicamente una de ellas, para no sobreajustar por variables dependientes y minimizar inestabilidades numéricas, en particular, **superficie cubierta**, ya mencionado, por poseer mayor relación con el resto de variables como se observa en la matriz de correlación. Y, por razones equivalentes, se cree que se ve considerablemente afectado el rendimiento de la primera en la regresión múltiple, dado que, por operación del algoritmo de selección utilizado, la mayor influencia de esta variable se encuentra incorporada en el modelo.

En cuanto a la caracterización, el algoritmo k-means permitió identificar tres estructuras naturales de viviendas que se corresponden con segmentos diferenciados por escala y dimensiones. La estandarización previa de las variables fue un paso crítico para evitar que las diferencias en unidades de medida sesgaran el cálculo de distancias. La calidad de la segmentación fue respaldada por valores de Silhouette positivos y moderados, lo que indica que los grupos presentan cohesión interna y separación razonable. Sin embargo, la interpretación de los centroides requirió complementar la media con medidas robustas como la mediana para las variables discretas, dado que k-means opera en un espacio continuo y puede producir valores no observables (por ejemplo, 1.8 ambientes). Aun así, los clusters lograron capturar segmentos relevantes del mercado: unidades

pequeñas y económicas, propiedades de tamaño intermedio, unidades más amplias y aquellas con mayores comodidades y valores significativamente más altos en las variables de análisis.

4.1 Ventajas del enfoque aplicado

El enfoque utilizado presenta varias fortalezas. La combinación de análisis descriptivo, regresión y clustering permitió abordar el problema desde perspectivas complementarias (explicación, predicción y segmentación), lo que favorece una comprensión más amplia del comportamiento del precio. La validación cruzada aportó rigor estadístico y evitó seleccionar modelos sobreajustados, mientras que la estandarización y el análisis de correlaciones facilitaron la interpretación en un conjunto de datos con escalas heterogéneas. Asimismo, tanto la regresión lineal múltiple como k-means son métodos eficientes, reproducibles y ampliamente utilizados en análisis exploratorio de mercados inmobiliarios, lo que hace que los resultados obtenidos sean comparables con estudios similares y adecuados para una primera aproximación al comportamiento del mercado.

4.2 Limitaciones del análisis

A pesar de sus aportes, el estudio presenta limitaciones que condicionan el alcance de las conclusiones. La regresión lineal asume relaciones estrictamente aditivas y simples entre predictores y precio, lo cual constituye solo una aproximación a la realidad del mercado y puede generar sesgos si existen patrones no lineales significativos. Además, el modelo enfrenta riesgo de sesgo por variables omitidas como podrían ser antigüedad, estado edilicio, comodidades, cercanía a transporte o ubicación precisa podrían explicar mayor parte de la variabilidad del precio.

[X]


La distribución altamente asimétrica del precio y la presencia de posibles *outliers* afectan la estabilidad de las estimaciones, incluso después de la estandarización. En el caso del clustering, k-means es sensible al ruido y a los valores extremos, y asume grupos esféricos con varianza similar, lo que implica que los clusters deben interpretarse como aproximaciones generales y no como segmentaciones estrictas del mercado. Similar efecto pueden tener estos valores sobre las rectas generadas por regresión si se considera que dichos datos generan alto apalancamiento (también conocido como *leverage*) sobre las mismas. Algunas posibles soluciones y acercamientos a estos errores sistemáticos para futuros trabajos, se basan en la búsqueda de algoritmos con mayor robustez; por lo que sería útil recurrir a clusters como k-medoids (*PAM clustering*), la incorporación de pesos, o metodologías similares.

5 Referencias

- Alboukadel Kassambara. (2017). *Practical Guide to Cluster Analysis in R: Unsupervised Machine Learning* (Vol. 1). STHDA.
- Gareth James and Daniela Witten and Trevor Hastie and Robert Tibshirani. (2021). *An Introduction to Statistical Learning with Applications in R* (2nd). Springer.
- Hadley Wickham and Mine Çetinkaya-Rundel and Garrett Grolemund. (2023). *R for Data Science* (2nd). O'Reilly Media.
- Hansen, P. C. (2001). The L-curve and its use in the numerical treatment of inverse problems. En *Computational Inverse Problems in Electrocardiology* (pp. 119-142, Vol. 5). <https://www.sintef.no/globalassets/project/evitameeting/2005/lcurve.pdf>
- Kuhn, Max. (2024). *caret: Classification and Regression Training* [R package version 6.0-94]. <https://CRAN.R-project.org/package=caret>
- Nina Zumel and John Mount. (2020). *Practical Data Science with R* (2nd). Manning Publications Co.
- Peter J. Rousseeuw. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- Properati Data. (2020). *Buenos Aires Real State on sale*. Kaggle. Consultado el 15 de junio de 2026, desde <https://www.kaggle.com/datasets/alejandromendivil/bsas-realstate-on-sale>
- R Core Team. (2024). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>

6 Anexos

6.1 Anexo I: Datos faltantes



6.2 Anexo II: Matriz de correlación




Figura 11: Matrices de correlación.

6.3 Anexo III: Distribución del precio por m² en AMBA.




Figura 12: Mediana del precio por m² por barrio o localidad de Zona norte y Capital Federal. Las barras representan el rango intercuartílico.




Figura 13: Mediana del precio por m^2 por barrio o localidad de Zona norte y Capital Federal. Las barras representan el rango intercuartílico.

6.4 Anexo IV: Variación intra e inter clústers




Figura 14: Matriz de distancias en el espacio estandarizado (superficie cubierta, ambientes, dormitorios y baños). La diagonal (recuadrada) mide la cohesión intra-clúster como distancia media de las propiedades a su centroide; fuera de la diagonal, la separación inter-clúster entre centroides. Valores bajos en la diagonal y altos fuera de ella indican grupos compactos y bien separados.